Neural Network

Neural Network

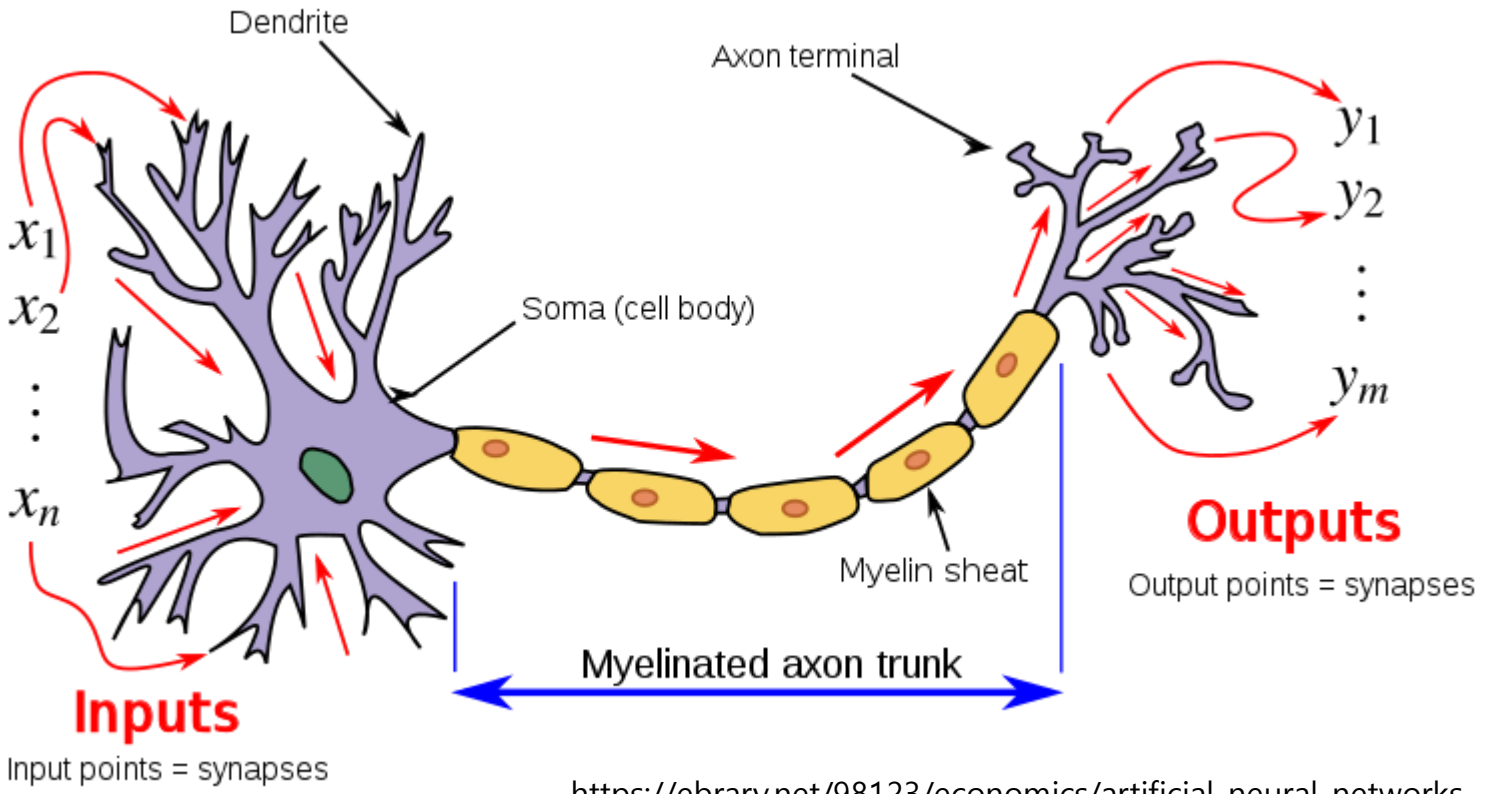

https://ebrary.net/98123/economics/artificial_neural_networks

참고자료

- 밑바닥부터 시작하는 딥러닝(사이토 고키, 2017)
- CS231n(http://cs231n.stanford.edu/)
- https://github.com/Harry24k

NEURAL NETWORK

선형회귀와 신경망

- 퍼셉트론
  - 다수의 신호를 입력 받아 하나의 신호를 출력
  - 선형회귀는 하나의 퍼셉트론으로 구현 가능

$$wx + b = y$$

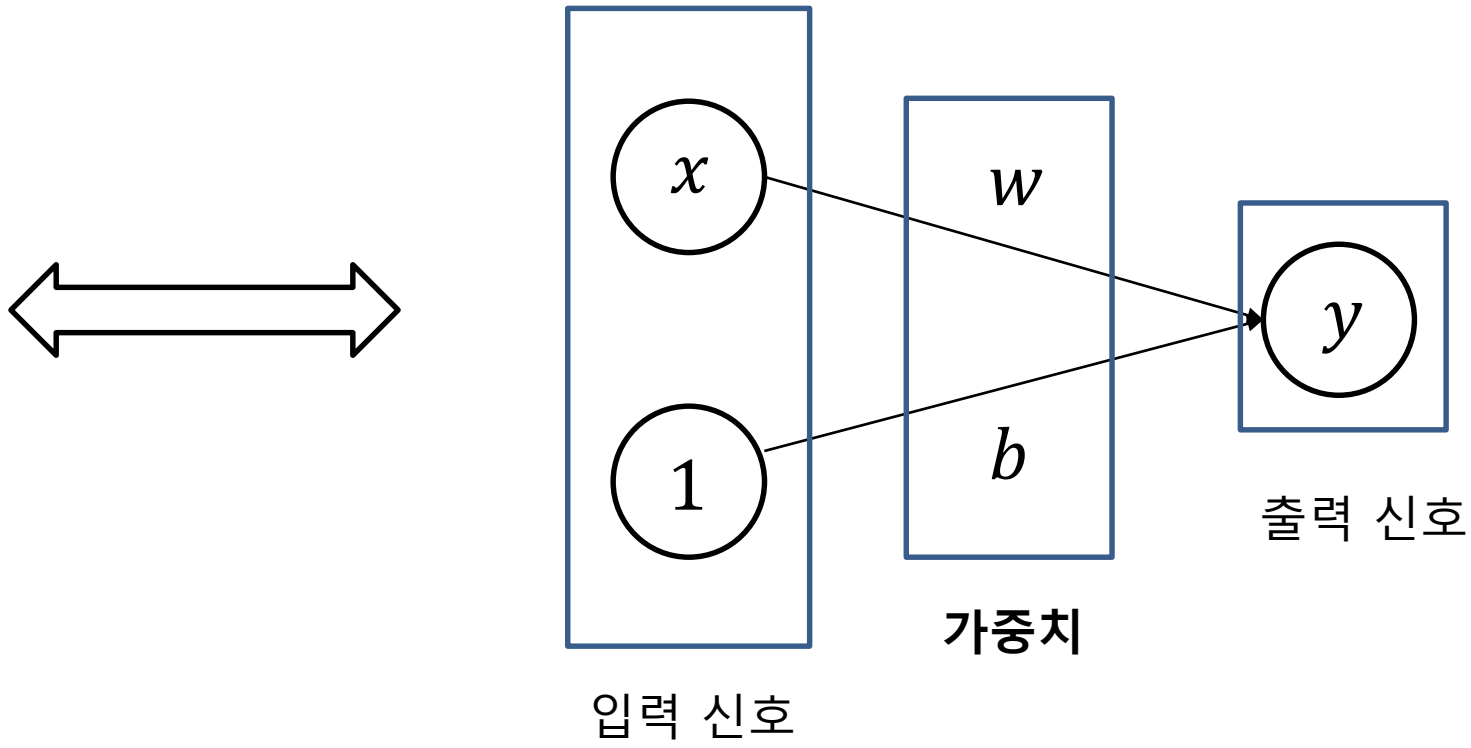

역전파와 순전파

목표: 역전파를 통해 좋은 가중치를 찾자!

- 순전파
  - 데이터처리 → 모델 구현 → 예측값 도출 → 손실함수 계산
  - 손실함수는 문제에 따라 정의됨
- 역전파
  - 기울기계산 → 개선방향 구하기 → **가중치 개선**
  - 개선 방향 = loss를 감소시키는 방향
  - 기울기 방향의 (-)는 loss를 감소시키는 방향이다

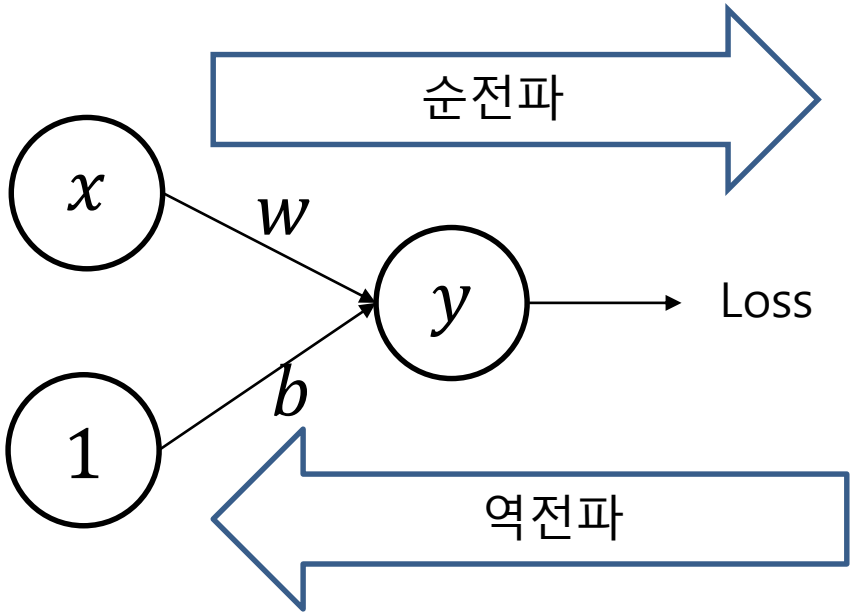

Gradient Descent

- 손실함수의 기울기를 통해 손실함수를 줄이는 방법
  - 초기점에서 출발
  - 초기점에서 기울기를 구함
  - 기울기의 반대 방향으로 움직임
  - 움직이는 정도는 learning rate를 통해 조절함.

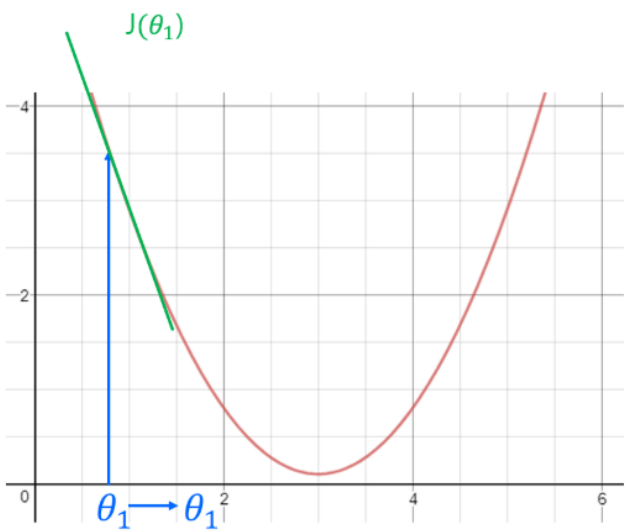

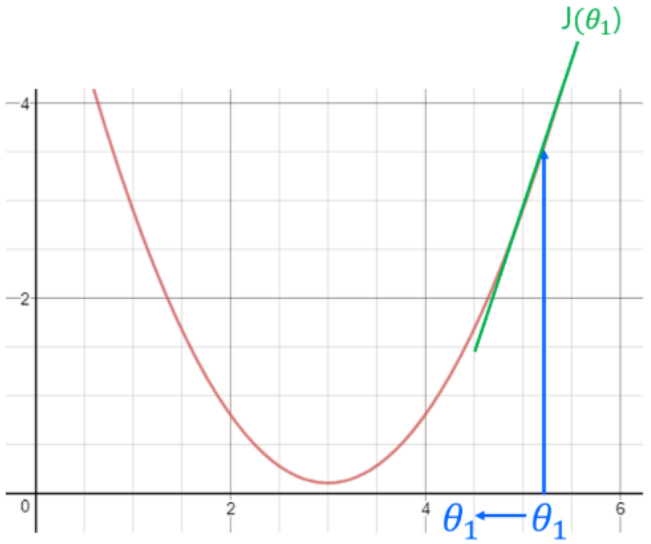

Gradient

- Gradient
  - $f: R^n \rightarrow R$인 real valued function에 대해서,

$$\frac{\partial f}{\partial \boldsymbol{x}} := \nabla f(\boldsymbol{x}) \overset{def}{=} \begin{bmatrix} \frac{\partial f}{\partial \boldsymbol{x}_1} \\ \vdots \\ \frac{\partial f}{\partial \boldsymbol{x}_n} \end{bmatrix} \in \Re^{n \times 1}$$

    - ∂: partial derivative

Chain Rule

- 연쇄 법칙

$$\frac{\partial f}{\partial x_j} = \sum_{i=1}^{m} \frac{\partial f}{\partial u_i} \frac{\partial u_i}{\partial x_j}$$

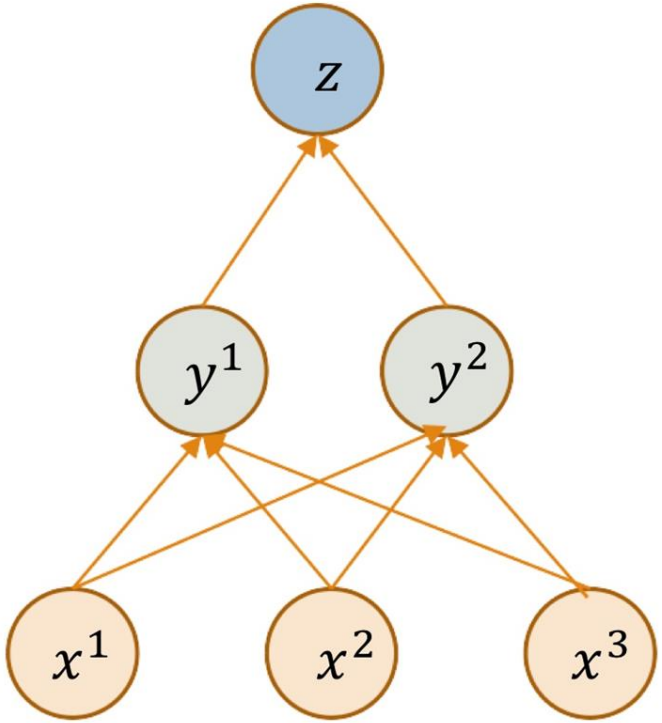

Back-propagation

http://cs231n.stanford.edu/

- Chain Rule
  - Chain rule을 이용하면 weight를 업데이트 할 수 있다.

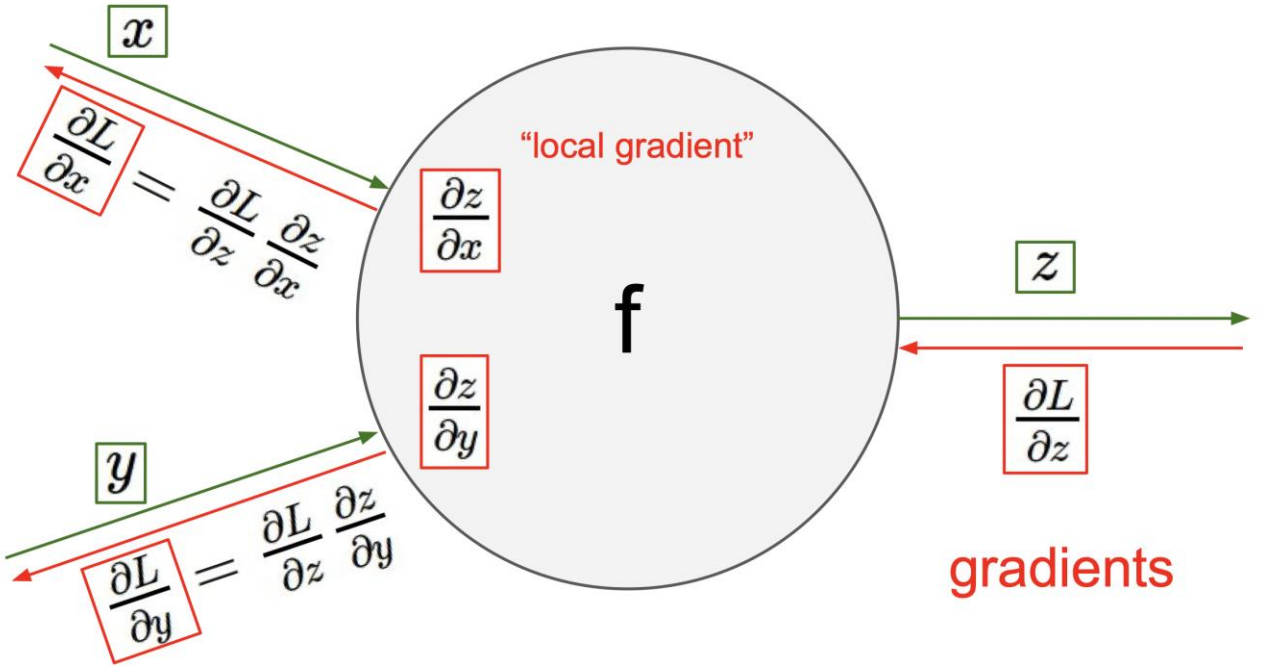

선형 신경망

- 실습 1

```
lr = 0.01

for step in range(20):
    pre = w*x
    cost = ((pre - y) ** 2).sum() / len(x)
    #(wx-y)^2 미분 시 2(wx-y)*x
    grad = 2*(pre-y).view(5).dot(x.view(5))/len(x)
    w -= lr*grad

    if step % 5 == 0 :
        plt.scatter(x.numpy(), y.numpy())
        plt.plot(x.numpy(), pre.numpy(), 'r-')
        # w.size() = 1*1, grad.size() = 1
        plt.title('step %d : cost=%.4f, w=%.4f, grad=%.4f' % (step, cost.item(), w.item(
        plt.show()
```

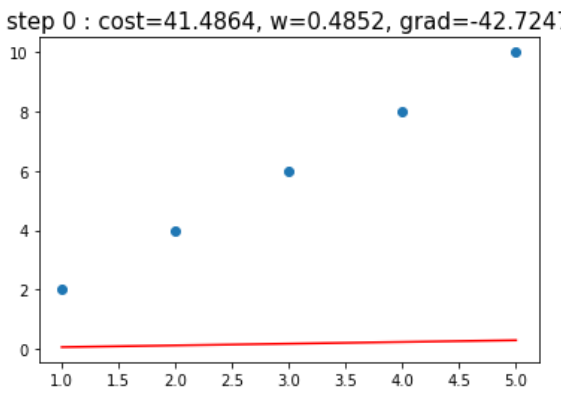

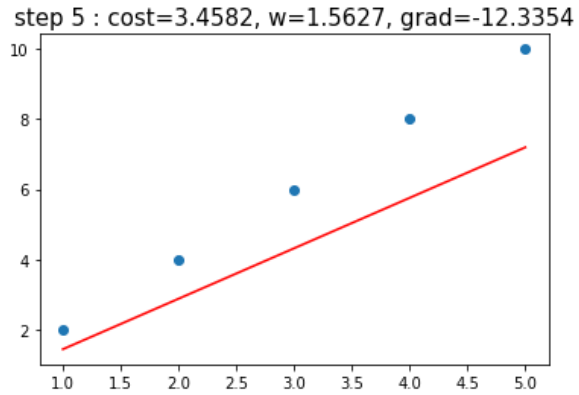

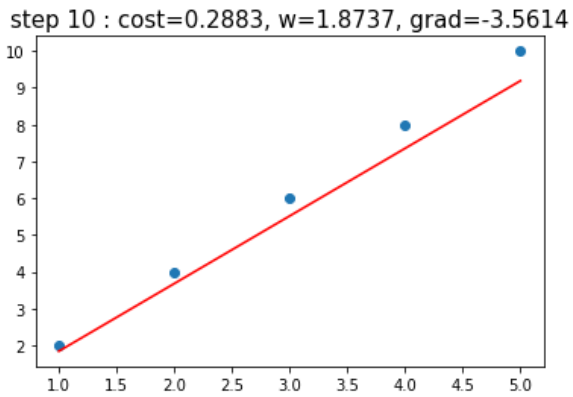

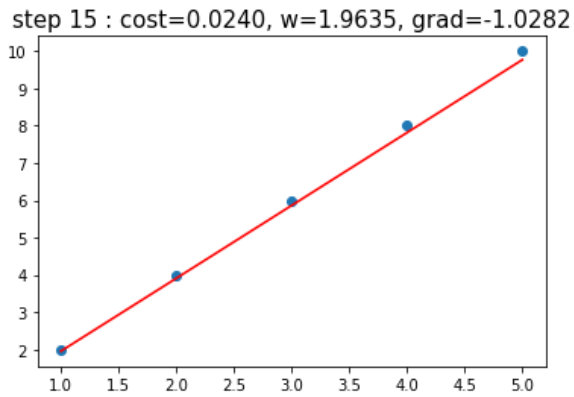

선형 신경망

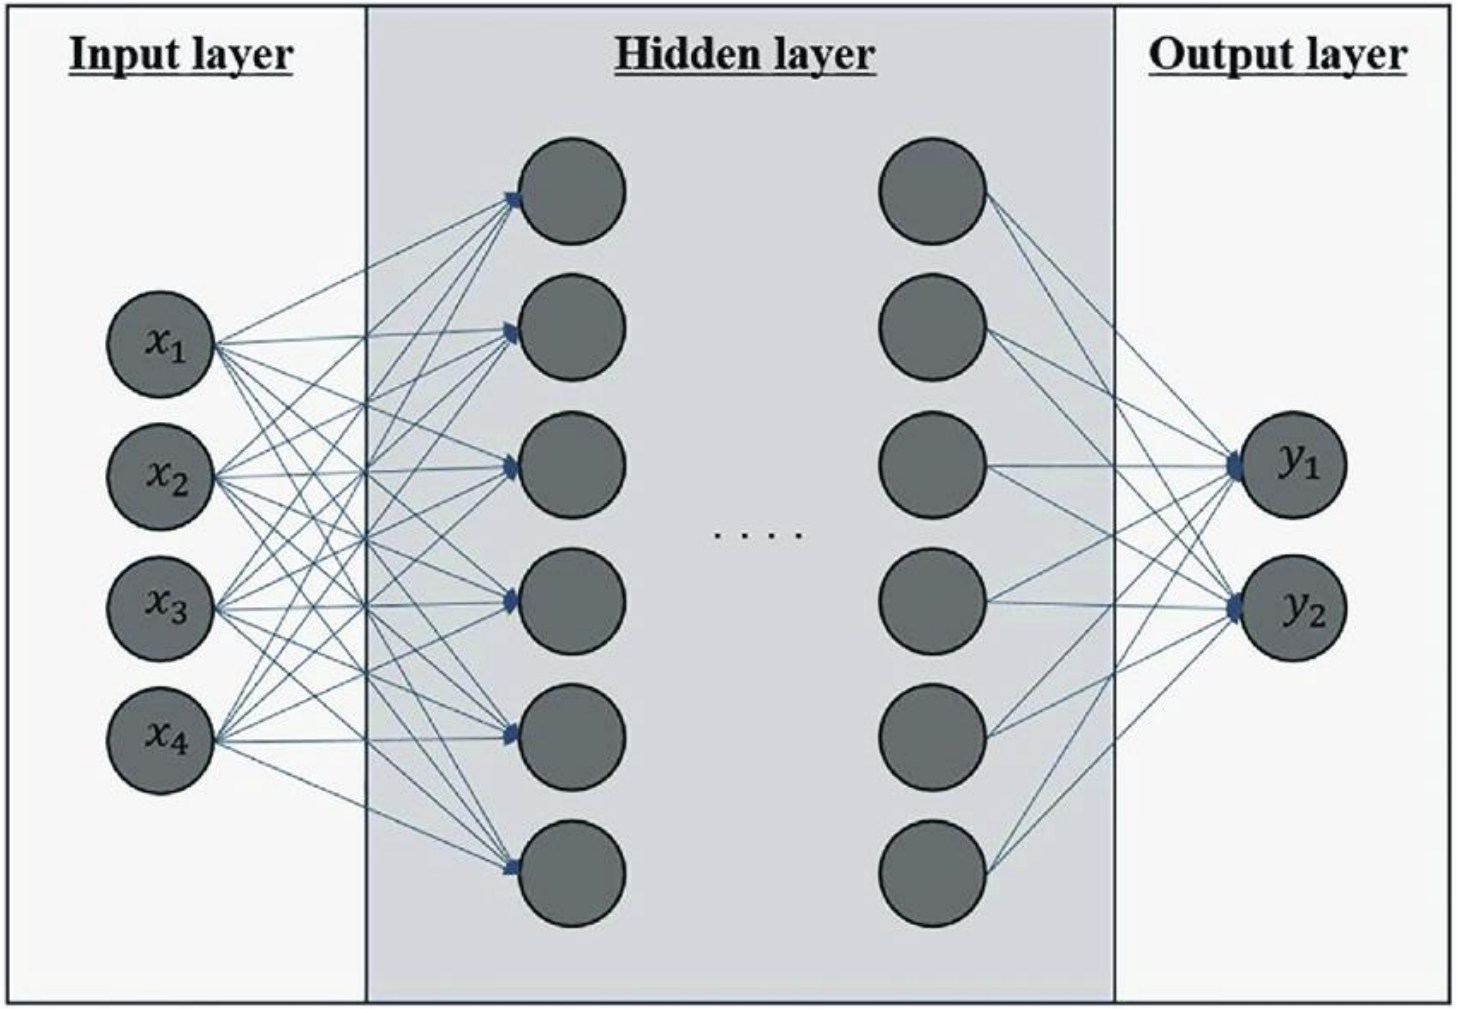

모든 퍼셉트론이 선형이라면?

선형 신경망

- 실습 2
  - $y = x^2$ 그래프를 linear layer 2개를 사용한 모델로 예측하면?

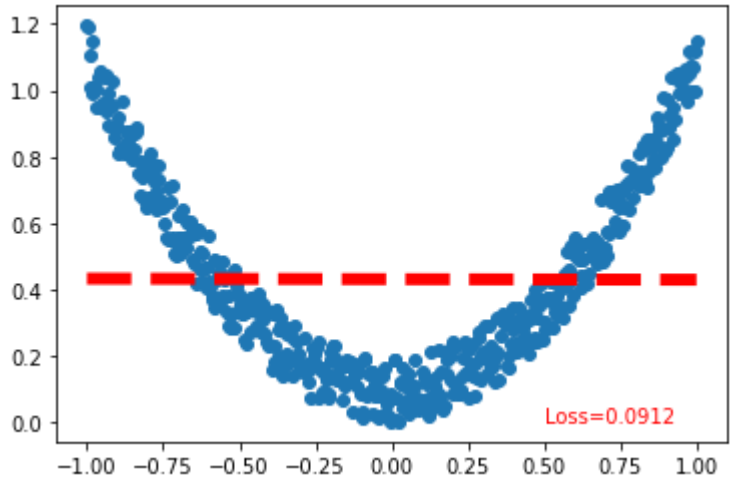

→ Linear layer를 여러 개 쌓는 것은 의미가 없다!

활성함수

- 비선형성
  - 선형결합의 선형결합은 선형결합이기 때문에, linear layer를 여러 번 쌓은 것은 의미가 없음
  - 즉, 비선형성을 갖는 함수가 필요함

    ➔ Activation function!

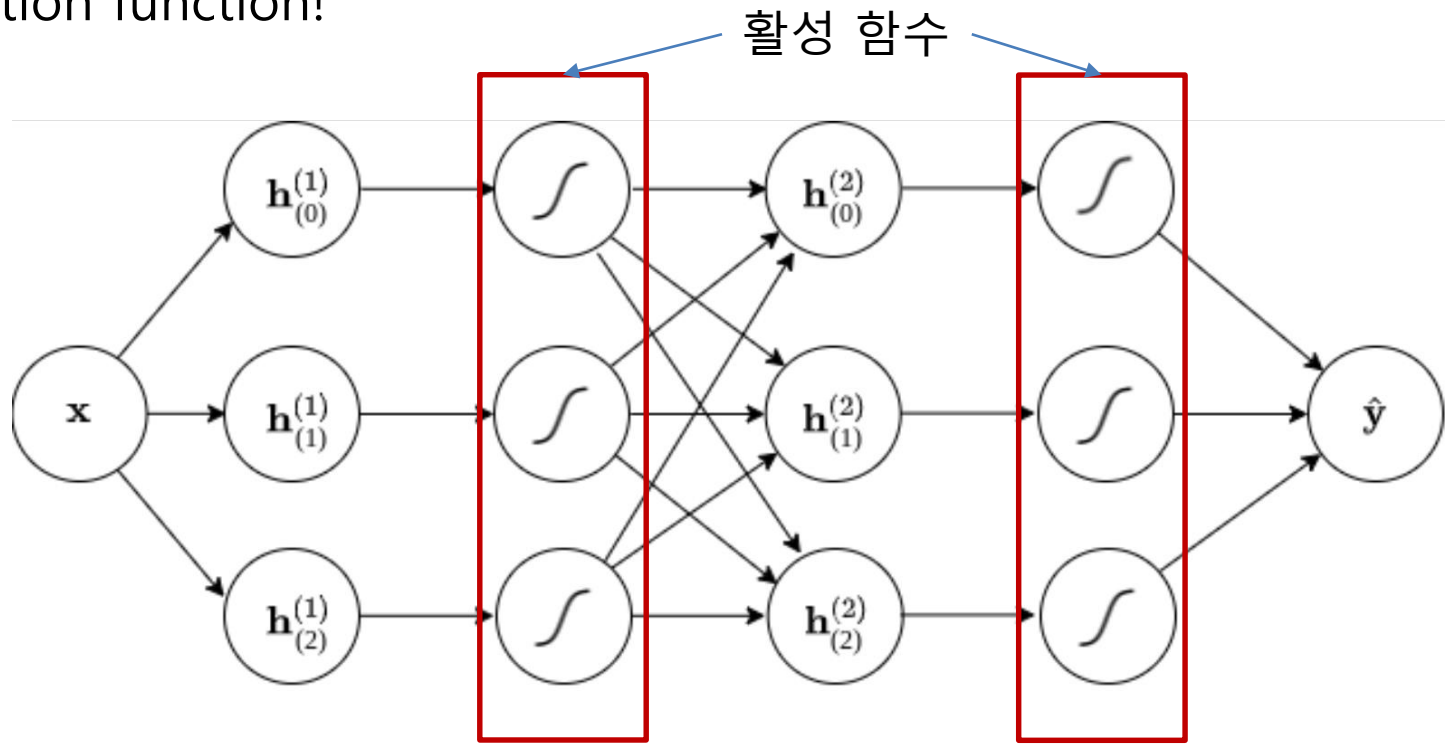

활성함수

Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

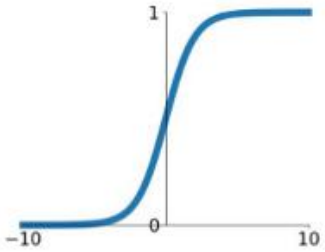

tanh

$$\tanh(x)$$

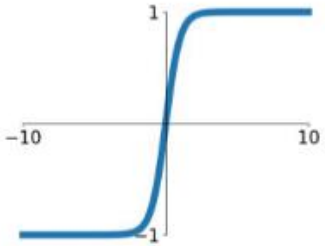

ReLU

$$\max(0, x)$$

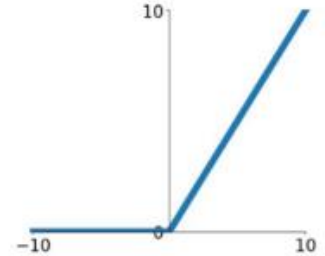

Leaky ReLU

$$\max(0.1x, x)$$

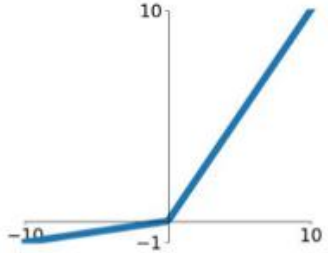

Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

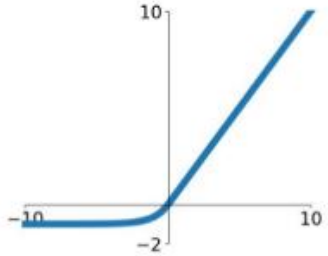

활성함수

- Sigmoid
  - 범위는 0과 1 사이 (s형태의 커브 생성)
  - 미분 가능 (기울기가 항상 1보다 작음)
  - Binary classification에서 출력층에서 사용(0.5보다 작으면 0, 0.5보다 크면 1로 분류)
- Softmax
  - N개의 다른 이벤트에 대한 확률 분포
  - 일반적으로 각 대상 클래스의 확률 계산, 모든 확률의 합 = 1
  - Multiclass classification 문제의 출력층에서 사용

활성함수

- ReLU
  - 입력값이 0보다 크면 입력값을 그대로 출력, 0보다 작으면 0을 출력
  - 값을 그대로 보내기 때문에 계산 및 학습이 빠름
  - 은닉층(hidden layer)에서 많이 사용함

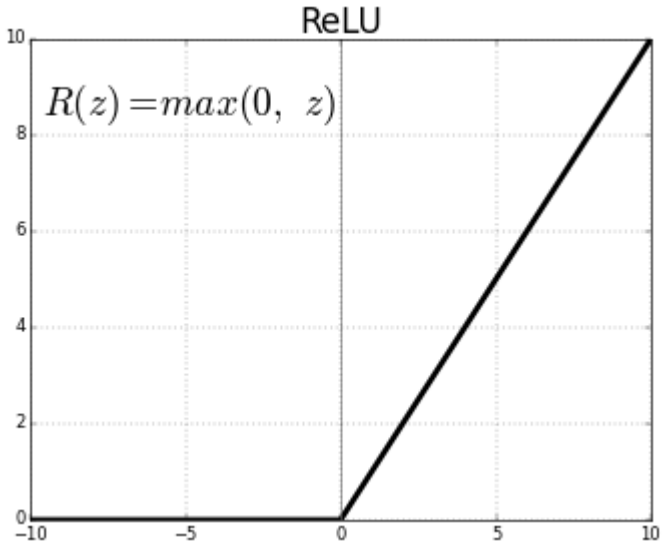

활성함수

- 실습 3
  - Linear layer와 activation function을 사용해서 $y = x^2$ 그래프를 예측

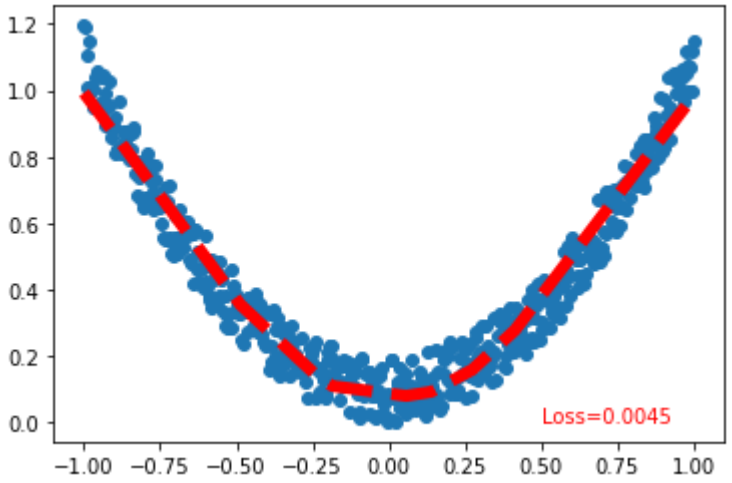

→ Activation function을 사용하면 비선형성을 나타낼 수 있다.

Loss function

- MSE Loss(mean squared error)
  - 예측한 값과 실제값의 차이를 제곱한 것의 평균(앞선 예시에서 사용)
- BCE Loss(Binary Cross Entropy)
  - Binary classification(0, 1의 class로 분류) 문제에서 사용하는 cross entropy
- CE Loss(Cross Entropy)
  - Classification에서 one hot label과의 cross entropy를 이용해 loss를 구함
  - Torch에서는 softmax와 cross entropy를 합쳐 놓은 것으로 제공

Summary

- Regression
  - Activation function(출력층): 항등함수
  - Loss function: MSE
- Binary classification
  - Activation function(출력층): sigmoid/softmax
  - Loss function: BCE/CEE
- Multicalss classification
  - Activation function(출력층): softmax
  - Loss function: CEE

Optimizer

- SGD(stochastic gradient descent)
  - $w' = w - lr * grad$
  - 각 sample 혹은 batch에 대해 반복 시행
  - 최적 경로가 아닐 수 있음
  - 계산량이 적기 때문에 빠른 학습 가능
- GD(gradient descent)
  - $w' = w - lr * grad$
  - 모든 training data에 대해 반복 시행
  - 최적 경로를 탐색
  - 계산량이 큼

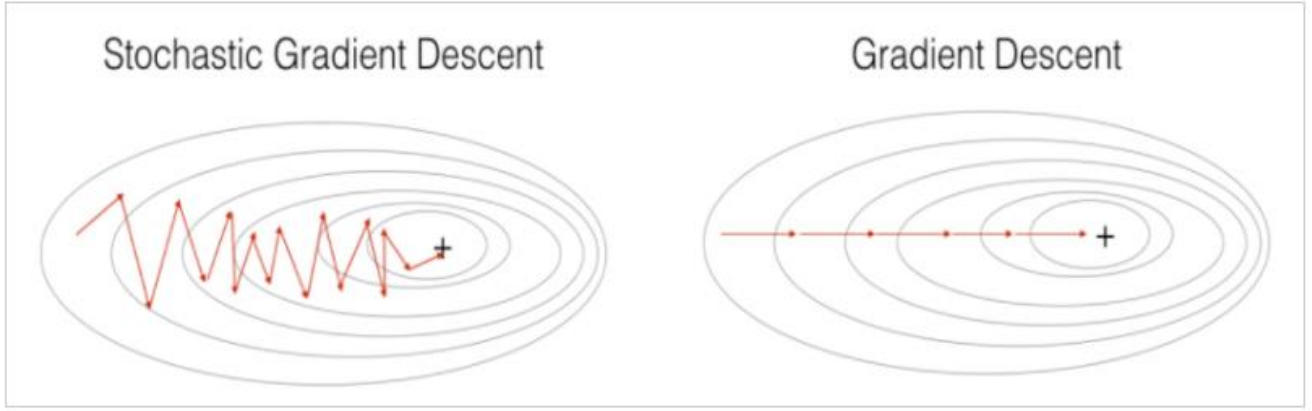

Optimizer

- SGD의 단점
  - 기울기가 최소점을 가르키지 않는 경우 지그재그로 움직임
- Momentum
  - 관성을 가지는 모델
  - 이전 변화량을 가중치 업데이트에 사용
  - $v' = \alpha * v - lr * grad$
  - $w' = w + v'$

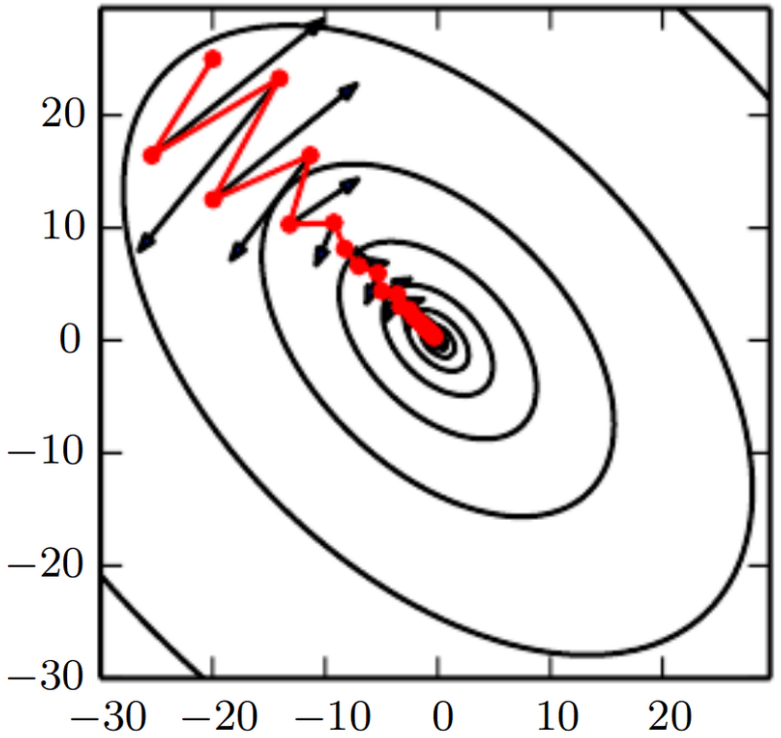

Optimizer

- AdaGrad
  - 학습률을 감소시키면서 학습을 진행함.
  - $h' = h + grad \odot grad$
  - $w' = w - lr \frac{1}{\sqrt{h' + \varepsilon}} grad$
  - 크게 움직일수록 학습률 감소
  - 단점: 어느 순간 이후 학습률 = 0이 될 수 있음.

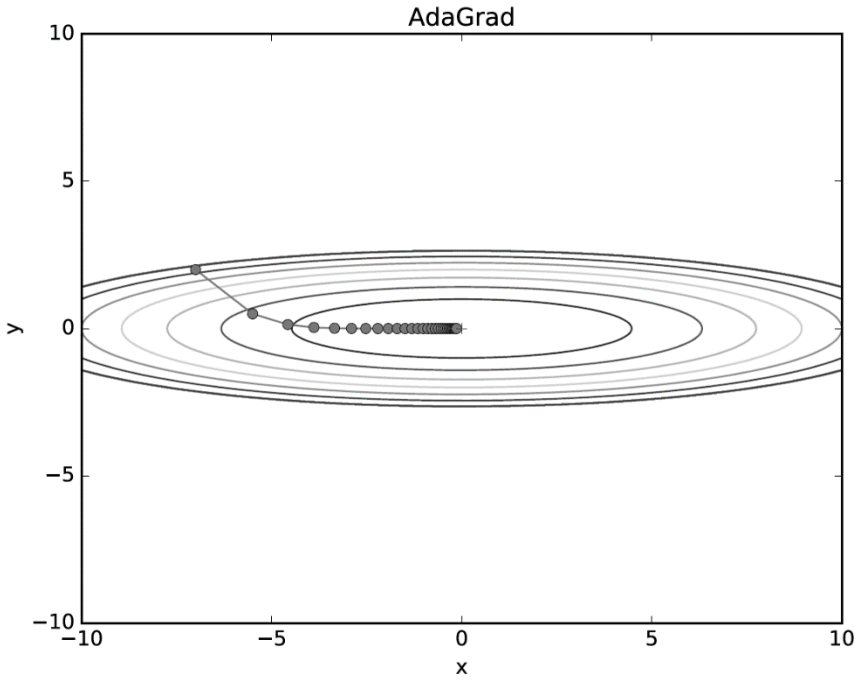

Optimizer

- RMSProp
  - 학습률을 감소시키면서 학습을 진행함.
  - 가장 가까운 기울기에 가중, 과거 기울기 반영 규모를 기하급수적으로 감소
  - $h' = \gamma h + (1-\gamma) * grad \odot grad$
  - $w' = w - lr \frac{1}{\sqrt{h' + \varepsilon}} grad$
- Adam
  - **Ada**grad + **M**omentum
  - 매개변수 2개 지정
  - RMSProp를 일반화

Batch Training

- Batch Training
  - 한번에 하나의 이미지만 학습하면 학습속도가 느림
  - 한번에 전부 다 학습시키면 out of memory
  - 적당한 양의 데이터를 묶어 한번에 학습시킨다
  - 적당한 양 = Batch size
- Epoch
  - 한 데이터가 총 몇 번 학습에 사용되나?
- Iteration
  - 1 epoch에 총 몇 개의 batch를 사용하냐?

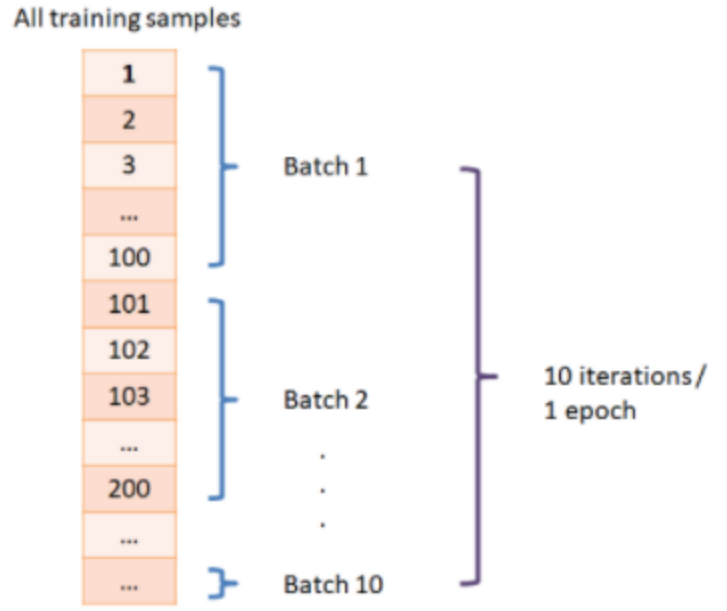

https://geniewishescometrue.tistory.com/entry/ML-DL-WIKI-BatchBatch-sizeEpochIteration

MNIST

- MNIST: 손글씨 숫자 이미지 데이터
  - Training set: 60000장
  - Test set: 10000장
  - Size: 28 * 28
  - 흑백 이미지

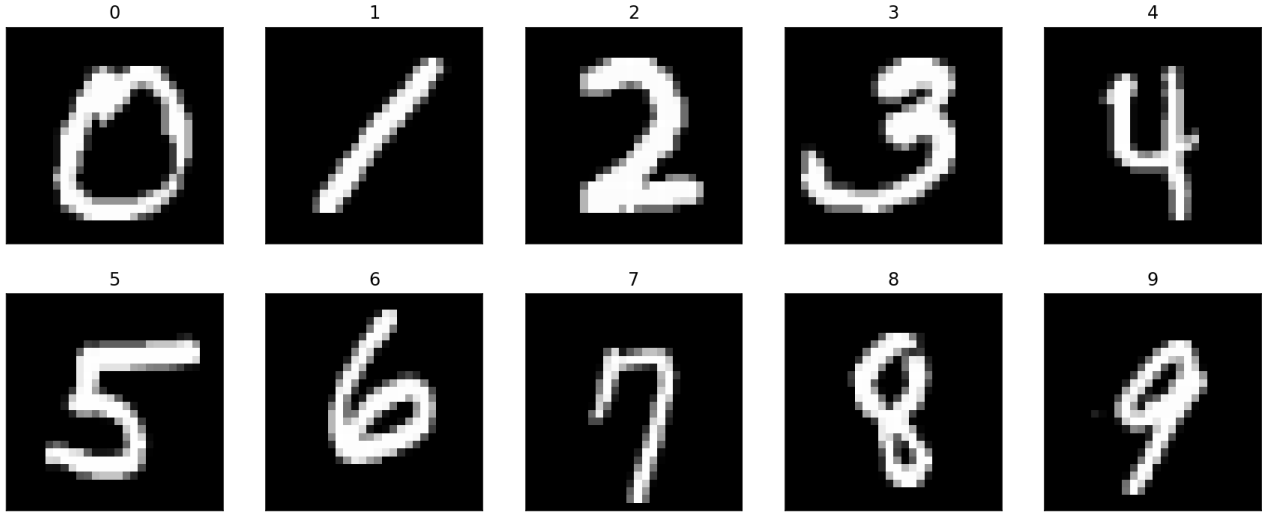

MNIST

- MNIST를 위한 Neural Network
  - Size : 28*28 = 784
  - Output : 10 (이미지가 0일 확률 ~ 9일 확률)

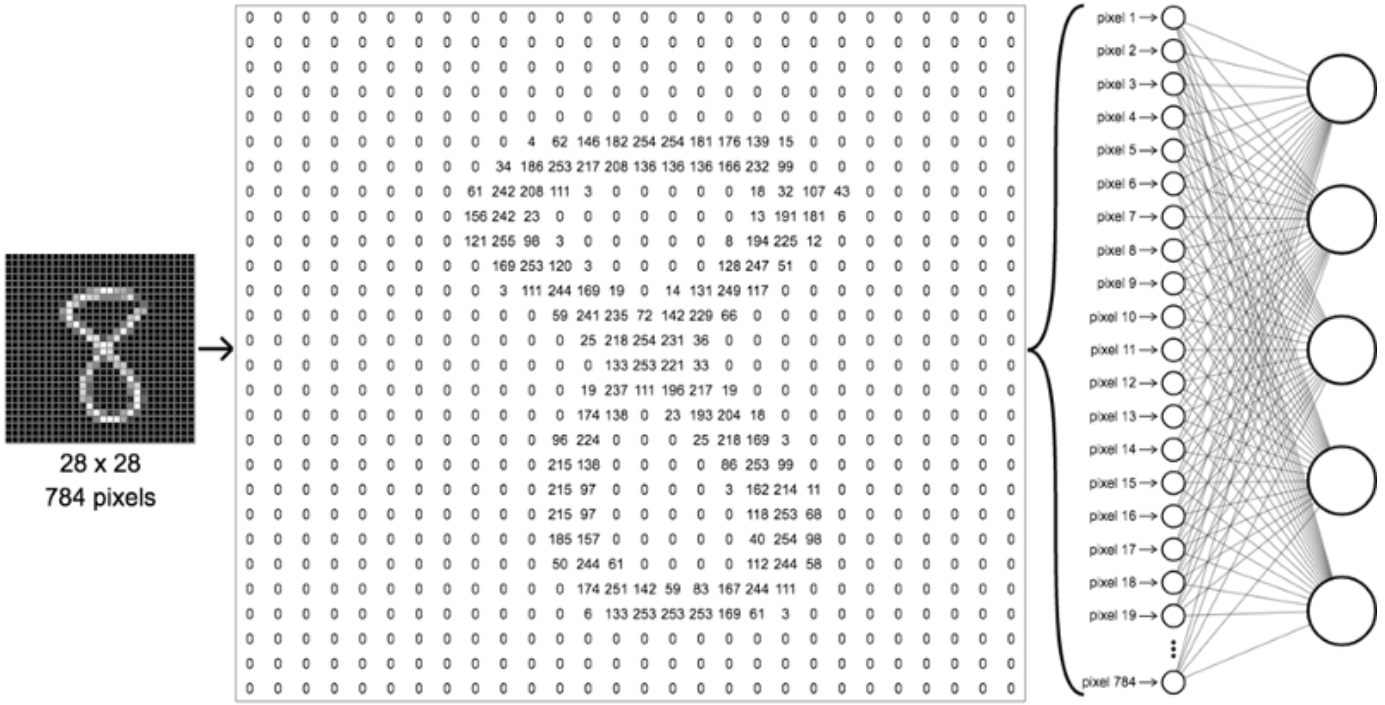

실습